

207BP 神经网络综合评价法

(1) 方法原理及思想

人工神经网络是模仿生物神经网络功能的一种经验模型,输入和输出之间的变换关系一般是非线性的。首先根据输入的信息尽力神经元,通过学习规则或自组织等过程建立相应的非线性数学模型,并不断进行修正,使输出结果与实际值之间的差距不断缩小。人工神经网络通过样本的“学习和培训”,可记忆客观事物在空间、时间方面比较复杂的关系。由于人工神经网络本身具有非线性特点,且在应用中只需对神经网络进行专门问题的样本训练,它能够把问题的特征反映在神经元之间相互关系的权中,所以,把实际问题特征参数输入后,神经网络输出端就能给出解决问题的结果。

神经网络的特点是,神经网络将信息或知识分布储存在大量的神经元或整个系统中。它具有全息联想的特征,具有高速运算的能力,具有很强的适应能力,具有自学习、自组织的潜力。他能根据历史数据通过学习和训练能找出输入和输出之间的内在联系,从而能得出问题的解。另外,他有较强的容错能力,能够处理那些有噪声或不完全的数据。部分节点不参与运算,也不会对整个系统的性能造成太大的影响。

反向传播(Back Propagation, BP)神经网络是由 Rumelhart 等人于 1985 年提出的一种很有影响的神经元模型,它是一种多层次反馈性模型,使用的是由“导师”的学习算法。有广阔的应用前景。

(2) 模型介绍

人工神经网络是由大量的神经元节点构成的. 设网络的输入节点数为 m , 输出节点数为 n , 网络是 $R^m \rightarrow R^n$ 的映射, 对此有如下定理: 令 θ 为有界单调递增连续函数, K 为 R^m 的有界闭子集, $f(X) = f(x_1, x_2, \dots, x_n)$ 为 K 上的实值连续函数, 则对任意 $\varepsilon > 0$, 存在整数 N 和实数 $C_i, \theta_i (i = 1, 2, \dots, N)$ 和 $W_{ij} (i, j = 1, 2, \dots, N)$, 使

$$f'(x_1, x_2, \dots, x_n) = \sum C_i \Phi(\sum W_{ij} - \theta_j) (i, j = 1, 2, \dots, N) \text{ 满足}$$

$$\max |f'(x_1, x_2, \dots, x) - f'(x_1, x_2, \dots, x_n)| < \varepsilon$$

上述定理说明, 对任意 ε , 存在一个 3 层网络, 其隐含节点输出函数为 $\Phi(x)$,

输入和输出节点函数为线性的，3 层网络总输入输出关系为 $f(x_1, x_2, \dots, x_n)$ ，使得 $\max |f'(x_1, x_2, \dots, x) - f'(x_1, x_2, \dots, x_n)| < \varepsilon$ (其中, $x \in K$)

多指标综合评价模型由数据预处理器和 BP 网络 2 部分组成数据预处理器将评价指标体系中各个指标的属性值，按一定规则通过相应的效用函数进行归一化处理，BP 网络的结构包括网络层数、输入输出节点和隐节点的个数、连接方式。根据映射定理可构造一个包括输入层、隐含层和输出层的 BP 网络，其中输入层节点数 m 由数据预处理器产生的向量维数决定，即评价指标的个数；输出层节点数 n 为 1，即评价结果；隐含层节点数 $L = (m \times n)^{1/2}$ 。隐含层的输出函数为 Sigmoid 变换函数，输入和输出层节点函数为线性函数。Sigmoid 变换函数如下。

$$f(x) = \frac{1}{1 + e^{-x}}$$

(3) BP 神经网络步骤

基于人工神经网络的综合评价方法的步骤可概括如下：

1、前期分析

- 1) 确定评价指标集，指标个数为 BP 网络中输入节点的个数，
- 2) 确定网络的层数，一般采用具有一个输入层，一个隐含层，一个输出层的三层网络模型结构。
- 3) 明确评价结果，输出层的节点数为 1
- 4) 对指标值进行标准化处理

参数说明： n 输入层神经元数目, m 隐含层神经元数目, q 输出层神经元数目, M 训练样本模式对的数目。

2、具体学习算法步骤

- 1) 用随机数（一般为 $(-1, +1)$ 之间的数）初始化网络节点的权值和网络阈值。初始化：给各连接权 $\{w_{ij}\}, \{V_{ii}\}$ 及阈值 $\{\theta_i\}, \{r_i\}$ 赋予 $(-1, +1)$ 间的随机值。
- 2) 随机在样本集中选取一模式对提供给网络，模式对如下。

$$X_k = (x_1(k), x_2(k), \dots, x_n(k)), Y_k = (y_1(k), y_2(k), \dots, y_n(k)); k = 1, 2, \dots, M$$

3) 计算（输入层到隐含层）

$$y_i = f(\sum_{j=1}^n w_{ij} x_j - \theta_i), i = 1, 2, \dots, m$$

式中： x_j 表示第 k 个模式第 i 个结点值。

4) 计算（隐含层到输出层）

$$O_t = f(\sum_{i=1}^m V_{ti} Y_i - r_t)$$

5) 计算（[此步开始进行反向传播，修正权值](#)）

$$h_t(k) = (y_t(k) - O_t(k)) \cdot O_t(k) \cdot (1 - O_t(k)), t = 1, 2, \dots, q$$

式中： $y_t(k)$ 表示 k 个模式第 t 个期望输出节点值。

6) 计算 $V_{ti}(k) = V_{ti}(k-1) + \Delta V_{ti}(k)$ ，具体如下所示：

$$V_{ti}(k) = V_{ti}(k-1) + \alpha_1 \cdot h_t(k) \cdot y_i; i = 1, 2, \dots, m; t = 1, 2, \dots, q; 0 < \alpha_1 < 1$$

阈值 r_t 可根据具体问题设置，也可用下式进行动态设置调整（[可不考虑](#)）

$$r_t(k) = r_t(k-1) + \alpha_2 \cdot h_t(k); t = 1, 2, \dots, q; 0 < \alpha_2 < 1$$

7) 计算

$$e_t(k) = (\sum_{i=1}^q h_t(k) \cdot V_{ti}) \cdot y_i \cdot (1 - y_i)$$

8) 计算 $w_{ij}(k) = w_{ij}(k-1) + \Delta w_{ij}(k)$ 具体如下：

$$w_{ij}(k) = w_{ij}(k-1) + \beta_1 \cdot e_t(k) \cdot x_j(k); i = 1, 2, \dots, q; j = 1, 2, \dots, n; 0 < \beta_1 < 1$$

阈值 r_t 可根据具体问题设置，也可用下式进行动态设置调整（[可不考虑](#)）

$$\theta_i(k) = \theta_i(k-1) + \beta_2 \cdot e_t(k); t = 1, 2, \dots, q; 0 < \beta_2 < 1$$

9) 计算全局误差。

$$E = \sum_{k=1}^M \frac{1}{2} \sum_{t=1}^q (y_{kt} - O_{kt})^2$$

10) 随机在样本集中选取下一模式对提供给网络，返回到 3)，直到 M 个样本训练完毕。

11) 当误差小于给定的拟合误差，网络训练结束；否则转向 3)，继续训练。

如果随着迭代次数的增加，网络全局误差函数 E 不减少或是减少得非常慢，意味着 E 难以收敛，此时应适当采用过滤样本（剔除单误差较大的样本）或调节参数的方法（ $\theta_i, r_i, \alpha_1, \alpha_2, \beta_1, \beta_2$ ），促使 E 收敛。

（4）应用及效果分析

侯志东等^[8]提出的基于 Hausdauff 度量的模糊 Topsis 方法，首先通过模糊极大集和模糊极小集来确定模糊多属性决策问题的理想解与负理想解，再由 Hausdauff 度量获得不同备选方案到理想解与负理想解的距离及其贴进度，根据贴进度指标对方案进行优劣排序。该方法思路清晰，计算简单，操作比较容易。

该法是基于归一化后的原始数据矩阵，找出有限方案中的最优方案和最劣方案，然后得某一方案与最优方案和最劣方案间的距离（用差的平方和的平方根值表示），从而得出该方案与最优方案的接近程度，并以此作为评价各方案优劣的依据。

指标进行同趋势的变换的方法：根据专业知识，使各指标转化为“高优”，转化方法有倒数法（多用于绝对数指标）和差值法（多用于相对数指标）。但是该法的权重受叠代法的影响，同时由于其对中性指标的转化尚无确定的方法，致使综合评价的最终结果不是很准确。

[如下是一个 BP 神经网络模型。BP 神经网络模型可以借助 Matlab 神经网络工具箱或是 SPSS Clementine 数据挖掘软件进行求解。](#)

